
Détection de communautés dans les réseaux sociaux pour les systèmes de recommandation et le marketing ciblé.

Présentée par: MOUDDEN Hamza

Devant le jury :

Année Universitaire 2025-2026



Sommaire

01 Introduction et contexte

02 Problématique et Objectifs

03 Etat de l'art

04 Méthodologie

05 Résultats de la détection de communautés

06 Intégration du système de recommandation

07 Démonstration

08 Conclusion et perspectives




Introduction

Les plateformes de réseaux sociaux génèrent d'immenses réseaux d'interactions entre les utilisateurs.

- Facebook compte plus de 2 milliards d'utilisateurs actifs.
- Les interactions incluent les mentions J'aime, les partages, les commentaires et les abonnements.
- Ces interactions forment des réseaux complexes qui révèlent des schémas de connexion et de comportement entre les utilisateurs.




3



Contexte

Détection de communautés

- Les réseaux sociaux (Facebook, X, Instagram...) sont des graphes d'interactions.
- Chaque utilisateur est un point, chaque lien (like, partage, abonnement) est une connexion.
- La détection de communautés consiste à trouver automatiquement des groupes d'utilisateurs très connectés entre eux.




Contexte

Les membres d'une même communauté partagent-ils les mêmes goûts ?

Question : Est-ce que regrouper les utilisateurs de cette façon est réellement utile ?

Réponse : Oui, car les personnes très connectées socialement ont souvent :

- Des centres d'intérêt communs (sport, cuisine, high-tech, etc.)
- Des comportements d'achat ou de consommation similaires.




Motivation

Pourquoi la détection de communautés pour la recommandation ?

Le problème : Un nouvel utilisateur arrive sur une plateforme. Il n'a aucun historique d'achat ou de notation.

Les systèmes classiques (filtrage collaboratif) ne peuvent rien lui recommander car ils ont besoin de ses données passées.

Notre solution : On le rattache à une communauté existante (grâce à son réseau social).







Problématique

Malgré la diversité des algorithmes de détection de communautés, plusieurs défis subsistent :

- **Diversité des méthodes** : modularité, marches aléatoires, apprentissage profond, etc.
- **Évaluation limitée** : la modularité ne reflète pas toujours l'utilité réelle.
- **Comparaison insuffisante** : peu d'études comparent les méthodes de manière systématique.
- **Absence d'un cadre unifié** : difficile d'évaluer les performances en pratique.

Question de recherche: *Comment les différentes approches de détection de communautés se comparent-elles en termes d'efficacité et d'utilité pratique pour les systèmes de recommandation ?*






Objectifs de recherche

- Comparer les algorithmes de détection de communautés classiques et modernes sur des réseaux réels et synthétiques.
- Évaluer leurs performances à l'aide de la modularité, du NMI et de l'ARI.
- Intégrer les meilleurs algorithmes de détection de communautés dans un système de recommandation hybride.
- Visualiser les résultats à l'aide d'une application web interactive.



État de l'art – Méthodologie

Diagramme PRISMA



État de l'art – Algorithmes classiques

Approches basées sur la modularité

Algorithme	Principe	Limite / Avantage
Louvain (Blondel et al.)	Regroupe les nœuds en maximisant la modularité du réseau.	Rapide et efficace, mais peut générer des communautés faiblement connectées.
Leiden (Traag et al., 2019)	Améliore Louvain en optimisant la modularité avec une meilleure connexion interne des communautés.	Produit des communautés plus cohérentes et mieux connectées.

Approches basées sur les marches aléatoires

Algorithme	Principe	Limite / Avantage
Walktrap (Pons & Latapy)	Utilise des marches aléatoires pour identifier des groupes de nœuds fortement connectés.	Efficace pour les réseaux basés sur les flux d'information.
Infomap (Rosvall & Bergstrom).	Détecte les communautés en minimisant la description du parcours dans le réseau.	Rapide et performant, notamment sur de grands réseaux.
MCL (van Dongen)	Utilise des opérations d'expansion et d'inflation pour séparer les communautés.	Nécessite souvent un prétraitement ou une pondération adaptée du réseau.

État de l'art – Algorithmes classiques

Approches divisives

Algorithme	Principe	Limite / Avantage
Girvan-Newman	Supprime progressivement les arêtes ayant une forte centralité d'intermédierité pour séparer les communautés.	Complexité élevée ($O(n^3)$), peu adapté aux grands réseaux.
Kernighan-Lin (1970)	Divise le réseau en deux groupes en recherchant une partition optimale.	Nécessite souvent des partitions de tailles similaires.

Algorithmes basés sur la physique statistique

Algorithme	Principe	Limite / Avantage
Spin Glass (Reichardt & Bornholdt)	Approche inspirée de la physique utilisant l'optimisation par recuit simulé pour détecter les communautés.	Complexité élevée, peu adaptée aux réseaux de grande taille ($> 10\,000$ nœuds).


État de l'art – Algorithmes classiques

Approches basées sur la propagation d'étiquettes


Algorithme	Principe	Limite / Avantage
LPA (Raghavan et al.)	Les nœuds adoptent l'étiquette la plus fréquente parmi leurs voisins.	Gates et al. : algorithme fondamentalement instable.
FLPA	Mises à jour asynchrones avec mécanisme de mémoire.	Yang et al. : surpasse le LPA pour un paramètre de mélange $\mu \in [0,5 ; 0,7]$.
LPA-MNI (Li et al.)	Combine la modularité et l'importance des nœuds.	Améliore la précision et la robustesse.
CLPA (Li et al.)	Basé sur une optimisation sous contraintes.	Polyvalent et adapté à différents types de réseaux.
FluidC (Parés et al.)	Les communautés sont modélisées comme des fluides qui s'étendent progressivement dans le réseau.	obtient un ARI d'environ 0,9 sur un réseau de 500 000 nœuds.

État de l'art – Algorithmes modernes

Graph Neural Networks (GCN-GAT-VGAE-AE)



État de l'art – Applications



Méthodologie

Phase 1: Évaluation des algorithmes de détection de communautés

Catégorie	Algorithmes	Datasets	Métriques
Classiques (13)	Louvain, Leiden, Walktrap, Infomap, LPA, FLPA, LPA-MNI, CLPA, FluidC, Girvan-Newman, Kernighan-Lin, SpinGlass, MCL	7 real-world + LFR synthétiques	NMI, ARI, Modularité
Deep Learning (4)	GCN, GAT, VGAE, Autoencoder		

Phase 2: Intégration au système de recommandation

- Approches de recommandation : User-Based, Item-Based, SVD+Community, ALS+Community, BM25+Community.
- Dataset: UCI Online Retail (541,909 transactions)
- Métriques d'évaluation : F1@10 – Recall@10

Phase 3: Développement de l'application Web


Méthodologie – Datasets Utilisées

Datasets

Dataset	Karate Club	Dolphins	Football	Polbooks	Primary School	Facebook	LastFM
Nodes	34	62	115	105	236	4,039	28,281

Réseaux synthétiques LFR

Parameter	Values
Network Size (n)	500, 1,000, 5,000, 10,000, 50,000, 100,000
Mixing Parameter (μ)	0.3, 0.5, 0.7



LFR : de faible à grand μ

Méthodologie – Métriques d'évaluation

Métriques d'évaluation de la détection de communautés

Métrique	Objectif	Intervalle
Modularité (Q)	Évalue la qualité de la partition sans ground truth.	$[-1, 1]$
NMI	Mesure la similarité avec ground truth.	$[0, 1]$
ARI	Mesure la similarité corrigée de l'effet du hasard.	$[-1, 1]$

Métriques d'évaluation du système de recommandation (@K)

- Precision@K : Relevant items in top-K / K
- Recall@K : Relevant in top-K / Total relevant
- F1@K : $2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$


Résultats – Datasets Réels

Métriques de détection de communautés – Modularité






Résultats – Datasets Réels

Métriques de détection de communautés – NMI et ARI




Résultats – Datasets Synthétiques LFR

Métriques de détection de communautés – NMI




Résultats – Datasets Synthétiques LFR

Métriques de détection de communautés – NMI



Résultats – Datasets Synthétiques LFR

Métriques de détection de communautés – NMI




Résultats – Intégration du système de recommandation

Résultats du réglage des hyperparamètres

Modèle	Configuration par défaut	F1@5 (défaut)	Configuration optimisée	F1@5 (optimisé)
ALS	factors=20, reg=0.1, $\alpha=40$	0.149	factors=100, reg=0.1, $\alpha=10$	0.371
BM25	k1=1.5, b=0.75	0.178	k1=3.0, b=1.0	0.211
SVD	n_components=50	0.277	n_components=50	0.277


Résultats – Intégration du système de recommandation

Résumé des performances





Résultats – Intégration du système de recommandation

Résumé des performances




Démonstration




Conclusion et perspectives

Perspectives futures

Orientation	Objectif
Détection dynamique	Mettre à jour les communautés en temps réel de manière incrémentale.
Approche inter-domaines	Valider la méthode sur des jeux de données de films, de musique et de réseaux sociaux.
Explicabilité	Renforcer la confiance des utilisateurs grâce à des explications basées sur les communautés.



**Merci pour votre
attention**



28